微软商城用户行为分析

一、项目背景

当前全球数字消费与服务生态规模持续扩张，微软商城（Microsoft Store）作为覆盖硬件终端、软件应用、数字订阅、游戏内容的全品类服务平台，沉淀了海量全链路用户行为数据。这些数据中蕴含着用户偏好、产品价值、转化规律等核心商业价值，数据驱动的精细化运营已成为微软提升用户体验、优化产品分发效率的核心竞争力。

本实习项目聚焦微软商城用户行为数据，以数据工程能力培养、深度特征挖掘、多模型建模实践、业务价值转化为核心目标，通过系统化的数据分析全流程、工程化落地规范及算法建模任务，全面提升实习生在大数据处理、特征工程、模型构建与评估、业务洞察等方面的核心技能。

项目将围绕以下核心业务问题展开实践：如何高效处理亿级规模多品类用户行为数据，保障数据质量与处理效率？如何构建多维度、有区分度的特征体系，支撑后续建模任务？如何通过逻辑回归模型实现用户购买行为的精准预测？如何利用深度学习模型捕捉用户序列行为规律，提升预测效果？如何通过数据分析与建模结果，提炼可落地的业务洞察与决策建议?

二、数据概况

2.1 数据来源与规模

本项目采用微软商城用户行为数据集，包含全量用户行为记录，覆盖约100万独立用户和400万件商品与数字内容，完整记录了用户在平台上的浏览、收藏、加购、购买全链路交互行为，覆盖硬件设备、应用程序、数字订阅、游戏等多元品类。

2.2 数据集字段说明

字段名	数据类型	取值范围	详细说明
user_id	string	约100万种	用户唯一标识，用于区分不同用户
item_id	string	约400万种	商品/内容唯一标识，用于区分不同商品与数字服务
category_id	string	约1万种	品类唯一标识，用于划分商品/内容所属类别
behavior_type	string	1/2/3/4	用户对商品的行为类型：1=浏览(pv) 2=收藏(fav) 3=加购物车(cart) 4=购买(buy)

timestamp	string	-	行为发生的时间戳，格式为YYYY-MM-DD HH，精确到小时

第一阶段：数据工程体系搭建与理论储备

核心目标 完成大数据处理环境与工程化管理体系搭建，建立数字服务平台用户行为分析的理论基础，实现数据全流程自动化处理与质量管控。

具体任务

1. 工程化环境与版本管理搭建 配置Python大数据分析环境(Pandas、Dask、NumPy、PyArrow)，针对数据规模优化内存分配与计算资源调度。搭建Git版本管理体系，制定Commit Message规范与分支管理策略(main/dev/feature三级分支)，所有代码、文档、中间结果按目录规范同步至仓库。设计模块化项目目录结构，实现数据层、代码层、文档层、结果层的完全解耦。
2. 领域文献调研与技术栈储备 精读3-5篇用户行为预测经典论文(如《Deep Interest Network for CTR Prediction》《Wide & Deep Learning for Recommender Systems》《Behavior Sequence Transformer》等)，梳理核心算法思想与特征工程范式。调研行业主流数字平台数据分析技术方案，对比不同工具 (Spark vs Dask)、模型在亿级数据场景下的优劣。
3. 亿级数据加载与全流程清洗 完成数据集的获取与合规性校验，设计分块读取+并行处理方案，解决单节点内存溢出问题。执行多维度数据清洗：基于业务规则与IQR/3σ法则处理异常值，基于用户-商品-行为-时间四元组去重，统一时间格式并校验时间有效性。开发自动化数据质量校验脚本，实现数据完整性、一致性、唯一性的批量检测，生成可追溯的质量报告。
4. 数据预处理与中间表构建 完成数据类型压缩(如字符串转类别型、数值型精度适配)与非必要字段筛选，将数据转换为Parquet格式提升读写效率。构建用户、商品、时间三个维度的基础聚合中间表，为后续特征工程做预计算。

交付成果 符合规范的Git项目仓库(含完整目录结构与提交记录)；领域文献调研笔记；数据处理自动化脚本集(加载、清洗、质量校验、格式转换)；数据处理报告(含处理逻辑、质量评估结果、中间表设计说明)；预处理后的标准化数据集(Parquet格式)。

第二阶段：深度特征工程与多维度探索性分析

核心目标 构建多维度、高区分度的特征体系，通过全面的探索性数据分析挖掘微软商城平台用户行为规律与特征关联，为建模提供高质量输入。

具体任务

1. SQLite数据库搭建与SQL基础分析 设计符合第三范式的SQLite数据库表结构，创建用户行为主表、用户维度表、商品维度表、时间维度表。编写批量数据导入脚本，将预处理后的Parquet格式数据高效导入SQLite数据库，建立索引优化查

询性能。掌握SQL核心语法，完成基础数据统计分析：用户行为总量统计、各行为类型占比计算、日活/周活趋势查询、热门商品与类目排名。实现复杂SQL查询：用户行为序列提取、转化漏斗各环节数据计算、用户分群统计、商品复购率分析。建立Python与SQLite的交互接口，实现SQL查询结果与Pandas DataFrame的无缝转换，支持后续深度分析。

2. 全维度特征体系构建 基础特征扩展：在原有用户、商品、时间特征基础上，新增用户生命周期特征(活跃度等级、连续活跃天数、流失间隔)、商品生命周期特征(热度衰减系数、类目竞争度)、行为序列特征(相邻行为间隔、行为跳转概率、连续行为模式)。 隐式特征挖掘：基于用户-商品交互矩阵，通过SVD矩阵分解提取用户与商品的隐式语义特征；计算用户-商品、商品-商品的共现相似度与关联规则特征。 业务导向特征：基于RFM模型计算用户价值分，构建全链路转化漏斗特征(浏览-加购、加购-收藏、收藏-购买各环节转化率)，设计用户偏好强度得分(行为权重：购买>加购>收藏>浏览)。

3. 特征预处理与有效性验证 完成数值型特征标准化/归一化、类别型特征编码(Target Encoding替代独热编码处理高维类目特征)，针对稀疏特征实现预嵌入处理。通过相关性分析、互信息法、方差阈值法进行特征筛选，剔除冗余特征与低区分度特征。验证特征与目标变量(用户未来7天是否购买)的相关性，输出特征重要性预评估报告。

4. 多维度探索性数据分析 基础行为分析：统计用户行为类型分布、日活/周活趋势、用户活跃时段分布，识别高转化时段。 转化漏斗分析：拆解用户从浏览到购买的全链路转化效率，定位核心流失节点。 用户分群分析：基于RFM模型将用户分为高价值、潜力、流失、沉睡四类，对比不同群体的行为特征与转化差异。 商品分析：挖掘热门类目与爆款商品特征，分析不同类目商品的转化周期与复购率。 时间维度分析：对比工作日与周末、节假日与非节假日的用户行为差异。

交付成果 SQLite数据库文件(含完整表结构与索引)；SQL查询脚本集(基础统计、转化分析、用户分群等)；Python-SQLite交互工具类；完整的特征字典(含特征定义、计算逻辑、预处理方法、区分度评估)；特征工程脚本集与预处理后的特征数据集；特征有效性评估报告(含相关性热力图、重要性排序)；探索性数据分析报告(含至少8种核心可视化图表)；核心数据洞察总结(含用户行为规律、转化瓶颈、商品运营建议)。

第三阶段：多模型建模与性能优化

核心目标 完成传统机器学习与深度学习模型的全流程构建与调优，对比不同模型的性能差异，深入分析模型可解释性，探索模型融合方案提升预测效果。

具体任务

1. 样本构建与数据集划分 明确目标变量定义(用户-商品对未来7天是否产生购买行为)，构建正负样本集。采用分层抽样按7:2:1划分训练集、验证集、测试集，保证各数据集分布一致性。对比SMOTE过采样、欠采样与类别权重调整三种方案，解决购买样本占比低的类别不平衡问题。

2. 传统机器学习模型构建与调优 实现逻辑回归、XGBoost、LightGBM三种分类模型，完成模型初始化与基础训练。采用Optuna自动超参数调优框架，优化模型关键参数，以AUC为核心评估指标。对比三种传统模型的性能(AUC、准确率、召回率、F1分数)，分析各自的优势场景与局限性。

3. 深度学习模型构建与优化 实现基础序列模型(LSTM/GRU)与业务场景专用模型(DIN深度兴趣网络)，完成序列数据构建与特征嵌入。优化模型架构：调整嵌入维度、隐藏层单元数、Dropout比例，引入多头注意力机制提升序列特征提取能力。采用学习率衰减、早停(Early Stopping)策略防止过拟合，对比不同深度学习模型与传统模型的性能差异。

4. 模型融合与可解释性分析 设计Stacking模型融合方案，融合逻辑回归、XGBoost与DIN模型的预测结果，进一步提升整体性能。深入分析模型可解释性：基于特征系数解释逻辑回归，基于SHAP值解释XGBoost与DIN模型，识别影响用户购买决策的核心特征。分析模型预测错误样本的特征，总结模型在冷启动用户、长尾商品场景下的不足。

5. 业务落地模拟设计 基于模型预测结果，设计模拟A/B测试方案，明确实验分组、核心评估指标与实验周期。提出基于模型的精准营销与商品推荐优化建议，量化预期业务收益。

交付成果 单模型性能评估报告；模型融合方案与性能对比报告；模型可解释性分析报告(含SHAP可视化结果)；模拟A/B测试方案与业务落地建议。

第四阶段：成果沉淀与项目复盘

核心目标 完成项目成果的系统化整理与可复用封装，进行全面的项目复盘，提升技术总结与表达能力。

具体任务

1. 代码工程化封装 将数据处理、特征工程、模型训练、预测推理等模块封装为可复用的Python工具包，编写API文档与使用示例。完善代码注释与单元测试，提升代码的可读性与健壮性。

2. 项目文档与汇报材料撰写 撰写完整的项目总报告，涵盖项目背景、数据概况、技术方案、实验结果、核心洞察与业务建议。制作项目汇报PPT与技术分享PPT，梳理项目核心亮点与技术难点。

3. 项目复盘与总结 复盘项目全流程，总结数据处理、特征工程、建模过程中遇到的问题与解决方案。分析项目存在的局限性，提出后续优化方向(如引入Transformer架构、扩充外部数据、增加实时特征等)。

4. 成果提交与展示 整理所有项目成果，同步至Git仓库main分支，生成版本发布记录。进行项目成果汇报与技术分享。

交付成果 可复用的数字平台用户行为分析Python工具包(含API文档与使用示例)；完整的项目总报告(含所有分析与建模结果)；项目汇报PPT与技术分享PPT；最终Git仓库。