微软商城用户行为分析项目周报

汇报周期：2026 年 10 月 19 日至 10 月 23 日

本次内容：函数和方法注释补齐、重复值处理口径复核及客户小时分布分析。

一、 本周工作概述

本周根据上周反馈，补齐并统一了函数和方法的注释，并重点复核了重复值处理方式。此前按用户、商品、行为类型和发生小时四项去重，会将同一用户在一小时内真实发生的多次操作一起合并，因此需要先了解次数分布，再决定处理规则。

本次以未去重的原始 CSV 为基础，对全部 12,256,906 条记录重新统计，形成客户小时次数分布、同商品同行为出现次数分布，以及不同去重口径的影响对比。当前保留全部原始记录，高频时段单独列为待核查对象。

二、 具体工作与成果

1. 补齐函数和方法注释

沿用项目现有的注释风格，补充此前缺少的函数和方法说明，统一说明函数用途、参数和返回内容；涉及异常、数据路径和处理边界的部分，按实际逻辑补充说明，便于后续阅读和维护。

2. 调整重复值的判断思路

上周按四元组去重，共合并 6,043,527 条记录，占原始记录的 49.31%。这一结果只能说明相关字段相同，不能证明这些记录全部是错误采集。时间只精确到小时，同一客户可能在这一小时内多次浏览、收藏、加购或购买。

本次将两种统计单位分开。“客户 + 小时”的全部记录数用于观察活跃程度。“客户 + 小时 + 商品 + 行为”的出现次数用于分析相同字段的重复情况。两种口径分别统计，不直接将高次数等同于错误数据。

3. 取数口径与 90 条参考线的定义

（1）数据来源与时间范围：使用用户提供的 user_behavior.csv 全量 12,256,906 条原始记录，未抽样，未先用上周的去重表筛选。数据覆盖 2025 年 11 月 18 日 00 时至 12 月 18 日 23 时，共 31 天、744 小时。

（2）统计单位：以 user_id 与完整日期小时 time 组成一个“客户小时”。例如，同一客户在 11 月 18 日 09 时和 11 月 19 日 09 时分别计算。采用自然小时分桶，不使用滚动 60 分钟窗口；保留源时间，不进行时区转换。源数据仅精确到小时。

（3）次数定义：每个客户小时内的原始日志行数记为 n，包含所有商品以及浏览、收藏、加购、购买四类行为。字段完全相同的多行也全部计数，不按商品数、行为种类数或不同四元组数计数。客户和商品 ID 按文本处理。

（4）主分布与分位分母：只纳入 n≥1 的 682,940 个有记录客户小时，每个客户小时权重相同。同一客户可贡献多个小时，分母不是 10,000 名客户，也不是原始日志总行数；记录占比另以 12,256,906 条为分母。

（5）零值处理：10,000 名已出现客户乘以 744 小时可得到 7,440,000 个理论小时槽，其中 6,757,060 个无记录，占 90.82%。这些补零槽仅用于补充描述，不进入主分布与分位计算。无记录不能证明客户当时已注册且没有操作。

（6）区间边界：本次将 1≤n≤90 作为常规保留区间，n=90 包含在内；n>90，即从 91 条起，单列为高频待核查。本次只进行标记，不将超线时段截断为 90 条，也不自动整组删除。

90 条对应的分位位置

经验累计比例 F(90)=667,512÷682,940=97.7409%。因此，90 条约位于第 97.74 百分位，覆盖 97.74% 的有记录客户小时；它不代表 P90，本数据的 P90 为 45 条。

整数次数存在并列值：n<90 的累计比例为 97.6686%，恰好 n=90 的有 494 个客户小时。分位数采用最近秩法，即累计比例首次达到目标比例的整数次数；此处以 F(90) 标注参考线的位置。

4. 同一客户在同一小时内的操作次数分布

原始数据覆盖 2025 年 11 月 18 日 00 时至 12 月 18 日 23 时，共 31 天、744 小时，包含 10,000 名客户。统计得到 682,940 个有记录的客户小时。平均每个客户小时有 17.95 条记录，中位数为 9 条，95% 不超过 65 条，99% 不超过 118 条，最高为 862 条。

下表按有记录客户小时计算占比；在 90 与 91 条之间拆分区间，超线部分继续完整展示。

每小时记录数	客户小时数	客户小时占比	对应原始记录数
1	50,564	7.40%	50,564
2	76,841	11.25%	153,682
3	44,106	6.46%	132,318
4	48,177	7.05%	192,708
5	31,978	4.68%	159,890
6-10	121,673	17.82%	943,464
11-20	124,153	18.18%	1,849,153
21-50	129,031	18.89%	4,124,517
51-90	40,989	6.00%	2,694,602
91-100	3,954	0.58%	376,755
101-200	10,694	1.57%	1,381,528
201-500	771	0.11%	192,378
501-862	9	0.0013%	5,347
合计	682,940	100.00%	12,256,906

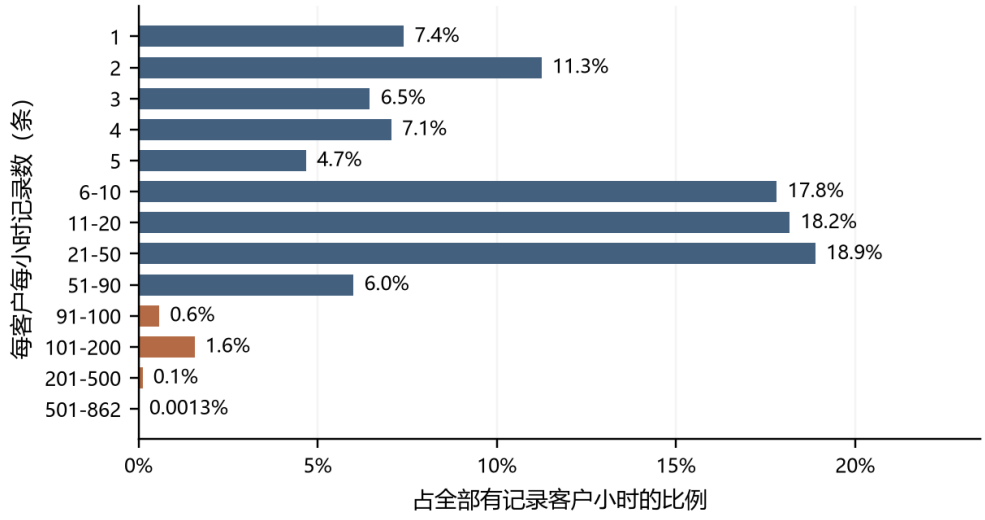


图 1 同一客户在同一小时内的原始记录数分布

蓝色为不超过 90 条的区间，棕色为超过 90 条的区间。前者共 667,512 个客户小时、10,300,898 条记录；后者共 15,428 个客户小时、1,956,008 条记录。全部区间合计仍与原始数据一致。

5. 同商品同行为的重复出现情况

按“客户、小时、商品、行为”分组，共有 6,213,379 个不同四元组。每组平均出现 1.97 次，最多出现 22 次；其中 92.08% 的分组出现不超过 3 次。

同一四元组出现次数	分组数	分组占比
1	2,370,182	38.15%
2	2,443,590	39.33%
3	907,561	14.61%
4	321,304	5.17%
5 次及以上	170,742	2.75%

进一步按行为类型比较，若每组只保留一条，影响如下。这里的“超额记录”是按该规则会被合并的记录，不表示已确认的错误日志。

行为	原始记录数	会合并的记录数	占该行为比例
浏览	11,550,581	6,014,702	52.07%
收藏	242,556	3,084	1.27%
加购	343,564	12,214	3.56%
购买	120,205	13,527	11.25%

浏览占全部超额记录的 99.52%，应作为主要核查对象。若逐组保留一条，购买记录会合并 13,527 条（11.25%）。目前缺少订单号和更精确时间，无法确认这些记录是否为重复下单。

6. 检查“每小时 90 条”参考线的适用范围

90 条参考线作用于客户小时总日志数 n。为避免与同商品同行为的重复次数混淆，同时列出两种粒度的结果。

统计粒度与条件	超过参考线的组数	对应原始记录数
客户每小时总记录数 > 90	15,428 个客户小时	1,956,008
同一四元组出现次数 > 90	0 组	0

超线时段占有记录客户小时的 2.26%，涉及原始记录的 15.96%，覆盖 3,357 名不同客户。若整小时删除会影响这部分日志，因此先核查商品和行为构成。同一四元组最多出现 22 次；最高 862 条的客户小时涉及 258 个商品，总次数高不能直接证明重复采集。

7. 本次采用的处理方式与结果核验

保留全部原始记录，按客户小时同时统计原始日志数、不同四元组数、不同商品数、各行为条数及单组合最大出现次数。以每小时 90 条为高频排查界限，超过参考线的 15,428 个时段已单列清单，状态均为待核查。

频数表加权后的记录总数与原始 12,256,906 条精确一致；两种全量聚合路径得到的客户小时分布一致，并使用原始 CSV 独立核对了 12 个高次数时段、12 个重复组及其源记录位置。读取前后的原始文件校验值一致。

三、 处理过程中需要注意的问题

1) “操作次数”目前指日志记录数，不能直接认定为真实点击次数、订单数或购买件数。同小时字段相同，也可能来自正常的多次操作。

2) 90 条是本次选定的排查界限，其分位位置由全量分布计算，尚不能据此证明错误或恶意行为。本数据没有事件唯一标识、订单号或分钟秒级时间，暂不能验证每条日志的真实来源。

3) 上周的 clean_v1、base_v1 和三张中间表属于旧版去重口径。本周没有覆盖这些历史结果；后续确认正式规则后，再决定是否重新生成。

四、 接下来的工作安排

继续核查高频时段，分别讨论浏览、收藏、加购和购买的保留方式。保留原始次数与四元组次数作对照，比较用户活跃度、商品热度及购买特征对处理口径的敏感性。

确定规则后，更新清洗程序及相关说明，重新生成受影响的数据和汇总表，并执行项目质量检查。之后再按项目安排建立第二阶段业务 SQLite 数据库，开展 SQL 统计分析。

五、 本周相关文件

1. Week2_report.pdf：本周工作、统计结果、处理思路和后续安排。

2. 客户小时操作次数与重复值分布.xlsx：分箱与精确频数、重复分布、分行为影响及高次数样本。

3. 客户每小时超过90条_待核查清单.csv：15,428 个高频时段及商品、行为和重复次数指标。

4. 90 条分箱分布表、分布图及取数口径说明：与本报告使用同一边界和分母，随附件保存。

说明：本报告沿用第一周周报结构。全量统计于 2026 年 10 月 24 日补充核验；函数和方法注释按本周实际完成情况登记。正式异常剔除及新口径 Parquet 重建尚未执行。